Korszerű Adatbázisok
Hadoop, Hbase

Gyakorlat

Hadoop

Hadoop telepítése - Linux

- Egyik megoldás (docker-ben futva)

```
# docker indítása docker-hubról
>  docker pull sequenceiq/hadoop-docker

> sudo docker run -p 50070:50070 -p 2122:2122 -p 8088:8088 -it sequenceiq/hadoop-docker:2.7.0
/etc/bootstrap.sh -bash

# user létrehozása
bash-4.1# adduser hadoopUser
bash-4.1# passwd hadoopUser                    //tetszoleges jelszo

# ahhoz hogy hozzáférjen a hadoop parancsokhoz
bash-4.1# echo "export PATH=$PATH:/usr/local/hadoop/sbin:/usr/local/hadoop/bin" >>
/home/hadoopUser/.bashrc

bash-4.1# hdfs dfs -mkdir /user/hadoopUser
bash-4.1# hdfs dfs -chown hadoopUser:hadoopUser /user/hadoopUser

# docker gép elérése
> ssh –p 2122 hadoopUser@localhost
```

- Másik megoldás – hasonlóan elindítani, mint a Windows-on

Hadoop telepítése - Windows

- Szükséges: Java7 vagy Java8
- Hadoop letöltése:
  - https://hadoop.apache.org/releases.html
  - 2.10.0 binary verziót
- Kicsomagolás c:\hadoop-2.10.0
- winutils és hadoop.dll letöltése
  - https://github.com/steveloughran/winutils/tree/master/hadoop-2.8.3/bin
  - bemásolni a c:\hadoop-2.10.0\bin alá

Hadoop telepítése - Windows

- Környezeti változók beállítása

HADOOP_HOME	**-->**	**C:\hadoop-2.10.0**
PATH	**-->**	**%HADOOP_HOME%\bin, %HADOOP_HOME%\sbin**

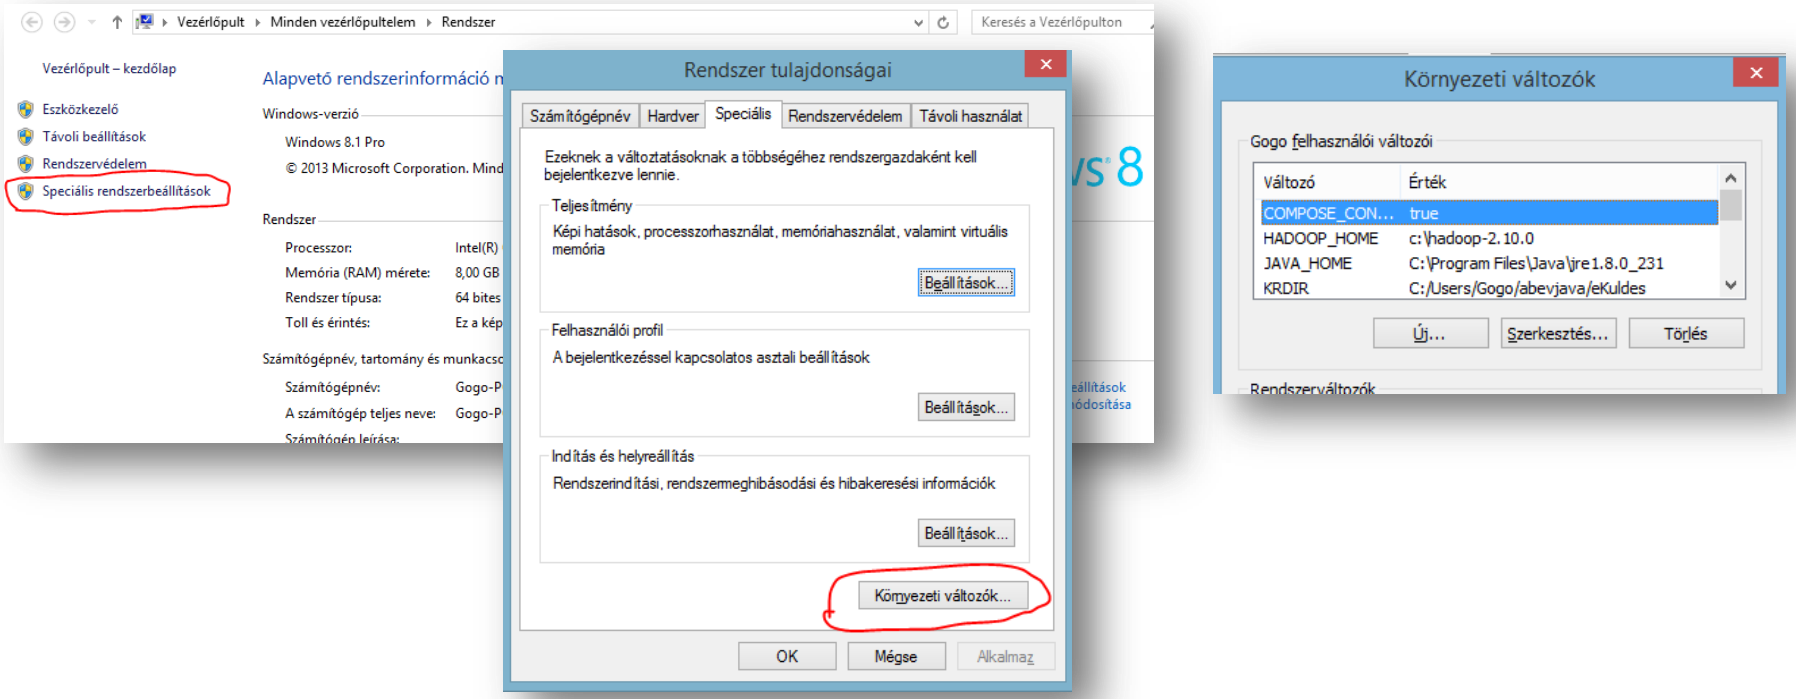

Hadoop konfigurálása

.\etc\hadoop\core-site.xml

```
<configuration>
  <property>
    <name>hadoop.tmp.dir</name>
    <value>C:\hadoop-2.10.0\temp</value>
  </property>
  <property>
    <name>fs.default.name</name>
    <value>hdfs://localhost:50071</value>
  </property>
</configuration>
```

.\etc\hadoop\hdfs-site.xml

```
<configuration>
  <property>
    <name>dfs.replication</name>
    <value>1</value>
  </property>
  <property>
    <name>dfs.namenode.name.dir</name>
    <value>/hadoop-2.10.0/data/name</value>
    <final>true</final>
  </property>
  <property>
    <name>dfs.datanode.data.dir</name>
    <value>/hadoop-2.10.0/data/data</value>
    <final>true</final>
  </property>
</configuration>
```

Hadoop konfigurálása

.\etc\hadoop\yarn-site.xml

```
<configuration>
  <property>
    <name>yarn.nodemanager.log-dirs</name>
    <value>C:\hadoop-2.10.0\userlog</value>
    <final>true</final>
  </property>
</configuration>
```

.\etc\hadoop-env.cmd

A JAVA_HOME-t állítsuk be kézzel, mert nem tudja a környezeti változóból venni

```
@rem set JAVA_HOME=%JAVA_PATH%
set JAVA_HOME=C:\Program Files\Java\jre1.8.0_231
```

Hadoop indítás

- Környezet tesztelése

```
> hadoop version
```

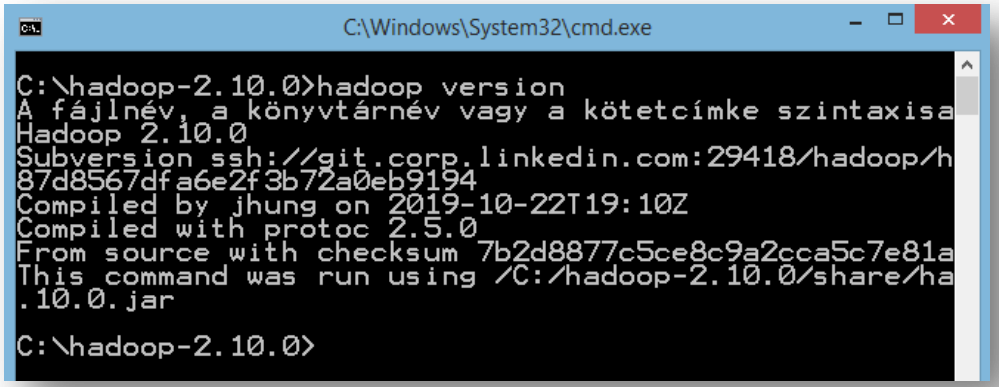

- HDFS formázása, ezt **csak egyszer** kell lefuttatni!

```
> hdfs namenode -format "ELTE"
```

- Hadoop környezet elindítása leállítása
  - Külön a HDFS és a Yarn vagy mindent

```
> start-dfs.cmd
> start-yarn.cmd
```

```
> stop-dfs.cmd
> stop-yarn.cmd
```

```
> start-all.cmd
```

```
> stop-all.cmd
```

Feladat 1

Készítsük el a Big Data 'Hello World'-nek számító, WordCount feladatot!

1. Egy tetszőleges szöveges fájlra számoljuk meg hogy az egyes szavak hányszor fordulnak elő.
   - Javítsuk a futtatást, hogy szó végén levő speciális karaktereket figyelmen kívül hagyjuk!

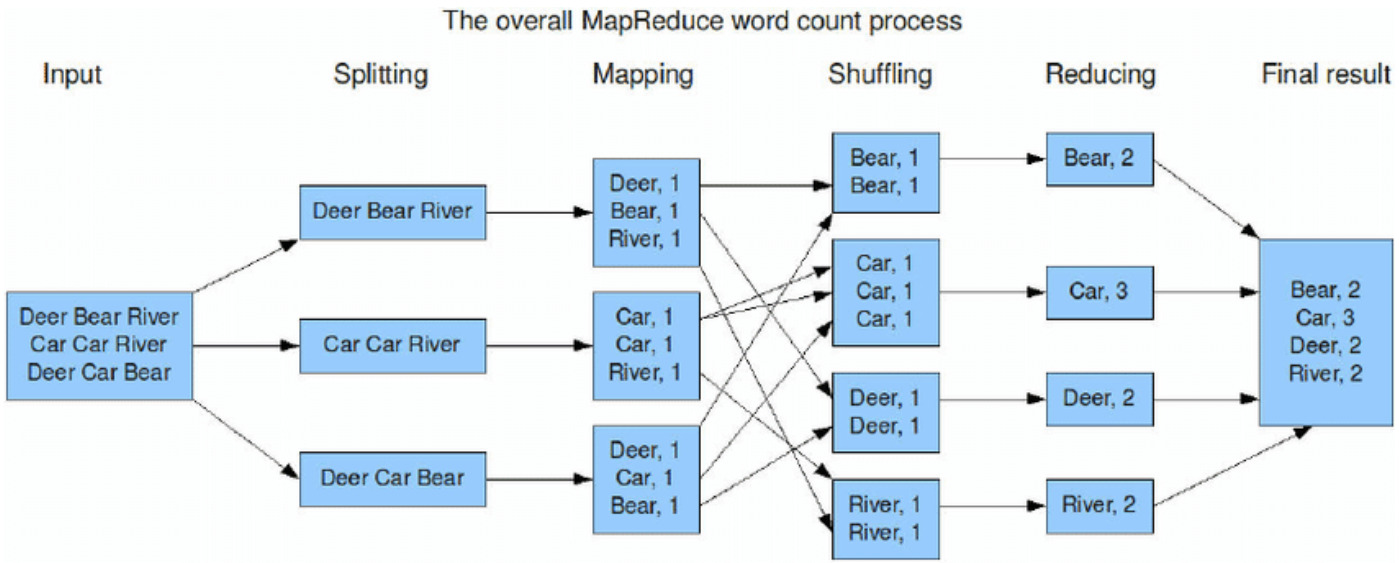

HBase

Hbase letöltése, indítás

- https://hbase.apache.org/
- 2.3.5-tel tesztelve
- windows-ra:
  - letölteni egy cygwin-t
  - hbase-env.sh
    - export HBASE_CLASSPATH=/home/Gogo/GogoHome/Downloads/hbase-2.3.5-bin/hbase-2.3.5/lib
  - hbase-env.cmd
    - set JAVA_HOME=C:\Program Files\Java\jre1.8.0_231

Hbase letöltése, indítás

- windows-ra:
  - hbase-site.xml

```
<property>
  <name>hbase.rootdir</name>
  <value>file:///C:/cygwin64/root/tmp/hbase/data</value>
</property>
```

- server indítás (cygwin): ./bin/start-hbase.sh
- kliens indítás (powershell): .\bin\hbase.cmd shell
  - megj: sokáig indul, mert valamit nem tud betolteni rendesen

'korszeru' tábla

rowId	hazik		letszam	
	nev	hatido	akt	max
04.08	hbase	'04.15'	19	19
04.12			21	21
04.15	pandas	'04.22'	24	24

04.12-nek a 'letszam:akt' több verzióban is szerepeljen:

1. 19
2. 20
3. 21

Feladatok

1. Kérdezzük le a server státuszát! ('summary', 'simple', 'detailed')
2. Segítség: table_help
3. Hozzunk létre egy 'korszeru' táblát és egy 'hazik' oszlopcsaláddal!
4. Listázzuk ki a táblákat!
5. Kérdezzük le a 'korszeru' tábla adatait!

Feladatok

6. Inaktiváljuk / aktiváljuk a 'korszeru' táblát!

7. Kérdezzük le hogy aktív-e?

8. Nézük meg milyen szűrési lehetőségek vannak az HBASE-ben?

9. Próbáljuk meg törölni a 'korszeru' táblát! (csak akkor lehet ha inaktív)

10. Addjunk hozzá új oszlop családot a 'korszeru' táblához! ('hely','letszam'(2 verziót tároljon))

Feladatok

11. Töröljük a 'hely' oszlop családot!

12. Töltsünk be adatot a 'korszeru' tábla 'letszam' oszlopcsalád 'akt' oszlopába: '04.07'=>19,'04.07'=>20,'04.07'=>21, '04.09'=>21, '04.13=>22 timestamp:16177900000'! (sorazon => ertek). A max oszlopba pedig: '04.07'=>27

13. Kérdezzük le hány elem van a 'korszeru' táblában!

14. Kérdezzük le a 'korszeru' táblát!

15. Kérdezzük le a 'korszeru' tábla 'letszam' oszlopcsaládját!

16. Kérdezzük le a 'korszeru' tábla értékeit verziókövetéssel!

Feladatok

16. Kérdezzük le a 'korszeru' tábla '04.07' sorát, oszlop szűréssel a 'letszam'-ra és timerange szűrésel 0-1720000000!

17. Töröljük a 'korszeru' táblából a '04.07' sor 'letszam:akt' értékét!

18. Kérdezzük le a táblát 10 verzióval!

19. Módosítsuk a '04.12'-es sor 'letszam:akt' értékét 25-re, majd nézzük meg a tábla értékét, majd töröljük azt és nézzük meg ismét az értéket!

Vége