Korszerű Adatbázisok
Spark, SparkSQL, Dataframes

Gyakorlat

source: SparkByExamples.com

Spark telepítése

- https://spark.apache.org/downloads.html
- Spark 3.1.1 – Hadoop 3.2
- Shell elindítása:
  - bin/pyspark.cmd
- Másik megoldás:
  - anaconda install
  - anaconda navigatorban: pyspark telepitese, majd:

```
from pyspark.sql import SparkSession
spark = SparkSession.builder.getOrCreate()
sc = spark.sparkContext
```

Feladatok

- Csináljuk egy WordCount-ot Sparkban!
- Hozzunk létre DataFrame-ket!
  - toDF()
  - CreateDataFrame
  - struktúra megadásával
  - record oszlop megadásával
  - CSV beolvasásával

Feladatok

- Kérdezzünk le oszlopokat a select() fv segítségével!
- Szűrjük az adatokat a filter() segítségével!
- Distinct(), DropDuplicate()
- Rendezzük a sort(), orderBy() segítségével!
- Használjuk az sql() fv-t!

Feladatok

- Csoportosítsunk és aggregáljunk:
  - groupBy()
  - sum()
  - count()
  - agg()
- Csináljunk joint 2 DataFrame-n!
- Aggregáljunk a select() fv-n belül!

Köszönöm a figyelmet!